

技术报告

评论文本分块与引用高亮

痛点

原系统从入库、建索引到检索、拼接，全程把「整条评论」当成最小检索单元。在评论平均长度只有几十字的场景下这种做法勉强能跑，但有三类问题反复出现。第一，一条评论里常常同时谈到「早餐很差、隔音不错、前台很好」等多个主题，把整条评论压成一个向量与一份倒排文档之后，单一主题就会被其它内容稀释，用户问「早餐怎么样」时，本该最相关的评论排名反而下降。第二，模型每次只能整段引用一条评论，前端也只能整条高亮，用户拿到的是一整段长文，还要自己再去文里找证据句，体验上离「精确定位被引用的内容」相去甚远。第三，长评论里的非主题部分容易把检索带偏，比如用户问网络，而某条评论几乎全在讲早餐、只在结尾提了一句 Wi-Fi，这种评论也会被错误地排到前面。

方案

整体思路是把「一条评论 = 一份文档」改成「一条评论包含若干句子级的 chunk」，让检索在更细的粒度上进行，同时让前端能直接知道哪一句被命中、把那一句标亮。具体的切分策略在「按句子切」「按固定长度滑窗切」「按主题相似度切」三种方案之间做了权衡。第三种效果上限最高但要先训练或调用一个主题分类器，工作量与依赖都比较重，最终选择的是「以句子切分为主，遇到特别长的句子再叠一层滑窗」，过短的句子与相邻句合并以避免噪声，整套切分逻辑大约 60 行，便于后续替换或对照实验。

检索过程也相应做了调整。让 BM25 先在更细的句子级 chunk 上做召回，结果整理完之后再按「来自同一条评论」做归并，每条评论只保留得分最高的那一句作为「代表句」，并把这句话在原评论中对应的字符位置一起返回。这样得到的结果对外仍然是「一条条评论」的形式，老的接口和前端组件都不用动，但每条评论上多挂了一个「这条评论是因为这一句被命中」的元信息。前端拿到这条信息后，把原评论里对应的那一段文字直接套上 `<mark>` 高亮即可，整个过程不依赖模型自己输出位置，因而既稳定又零额外成本。如果分块索引由于某种原因不可用，系统也会自动回退到原来的整条评论检索，不会因为优化引入风险。

效果

切分之后整库由 2171 条评论展开为 7883 个句子级 chunk，每条评论平均 3.63 个 chunk，平均文档长度由 41 词左右降到 12 词左右，但整库的词表规模几乎没变，说明这次改造改变的是「文档怎么切」而非「引入新的内容」。多样性方面也有明显变化，在 100 个 Query 的离线对比中，Top-30 命中里覆盖了将近 29 条不同评论，且每条评论平均只被一个代表句命中，避免了同一条长评论靠多个 chunk 反复挤占榜单的情况。表 ?? 给出了这些指标的前后对比，可以看到分块在保持词表稳定的前提下，让召回的粒度与覆盖面同步向更细的层级靠拢。

表 1: 分块与高亮的关键前后对比指标。

指标	基线	优化后
索引文档数	2171	7883 (3.63 chunk/评论)
平均文档长度 (词)	41.62	11.64
Top-30 覆盖不同评论数	——	28.99 (命中 1.04 句/评论)

更直观的变化体现在前端界面上。图 ?? 是优化后真实链路上的引用高亮效果，在「近期入住花园大床房的住客体验」这一问题下展开参考评论后，系统把真正与该问题相关的那一句以浅黄背景标出，其余文字保持正常底色，用户一眼就能确认「这条评论是因为这句话被引用过来的」，也省去了在长评论里手动定位证据的成本。

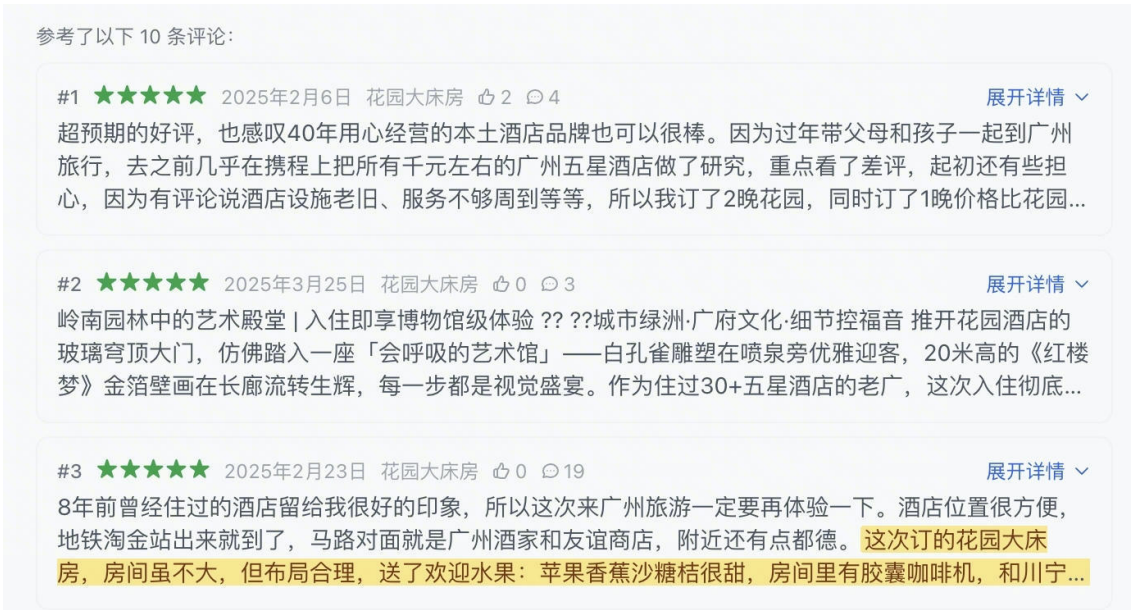


图 1: 展开第一条参考评论后，被命中的代表句以浅黄高亮，用户可以直接看出这条评论是因为哪句话被引用。

Prompt 结构化优化

痛点

原本的 Prompt 把所有信息都堆在一段长文本里，包括系统角色、历史对话、当前问题、检索回来的评论与摘要、以及十几条要求和引用规则。这样写出来的 Prompt 看着信息齐全，但模型并不容易抓住重点，几类问题会反复出现。一是回答经常先来一大段铺垫式的总结，再罗列优点缺点，对用户真正问的那个点反而轻描淡写。二是引用记号经常不合规，比如把四五条引用塞在同一个记号里、或者把同一个引用拆成两个挨在一起的小记号，前端解析与高亮就容易出问题。三是同一类问题在不同次回答里段落结构反复变动，前端很难做稳定的样式与跳转。这些问题的根源在于约束被平铺在一起，模型缺少一个明确可依的回答骨架。

方案

整体思路是借鉴常见的结构化 Prompt 写法，把原来的一团信息拆成五个清晰分工的小段：第一段交代「你是谁、能做什么、不能做什么」，约束模型只能基于检索回来的评论与摘要回答；第二

段提供「上下文」，包括今天的日期、当前问题、检索回来的评论与摘要，并按需注入历史对话，仅在用户出现「那、还有、它、是吗」这类追问性质的表达时，才把上一轮带进来，避免无关历史污染当前回答；第三段告诉模型「你这次要做什么、回答应该长成什么样」，给出一个固定的输出骨架；第四段把反幻觉、客观性、简洁性、闲聊边界、Markdown 等约束精炼成五条编号要求，让模型逐条对照；第五段是「自我校验」，要求模型在内心回看一遍引用是否合规、再把不合规的写法自己改正过来，但不把这个过程写进最终回答。这样改下来的好处是结构清楚、责任分明，模型每段都知道该做什么，输出也更接近一个稳定的模板，而不是每次自由发挥。

效果

经过五段式重构之后，模型在面对「近期入住花园大床房的住客体验如何」这类典型问题时，能稳定输出「先一句结论 + 几个带引用的要点 + 一句风险提示」的三层结构，引用全部以合规的蓝色徽标渲染，几乎没再出现把多条引用拆开或塞在一起的情况。图 ?? 是真实链路上的一次回答展示，开头一句先总括「房间舒适度普遍获得高度评价、卫生状况则呈现明显分化」，随后用三条带引用的要点分别覆盖房间布局与设施、文化氛围与空间体验、以及卫生方面的隐含风险，最后以一句关于敏感人群体验的风险提示收束，每条要点的引用都直接挂回到下方的评论卡片，用户可以点开继续验证证据。整体阅读体验比改造前的「长篇铺陈」明显更聚焦，前端也能依赖这个稳定结构做二级渲染与样式收敛。

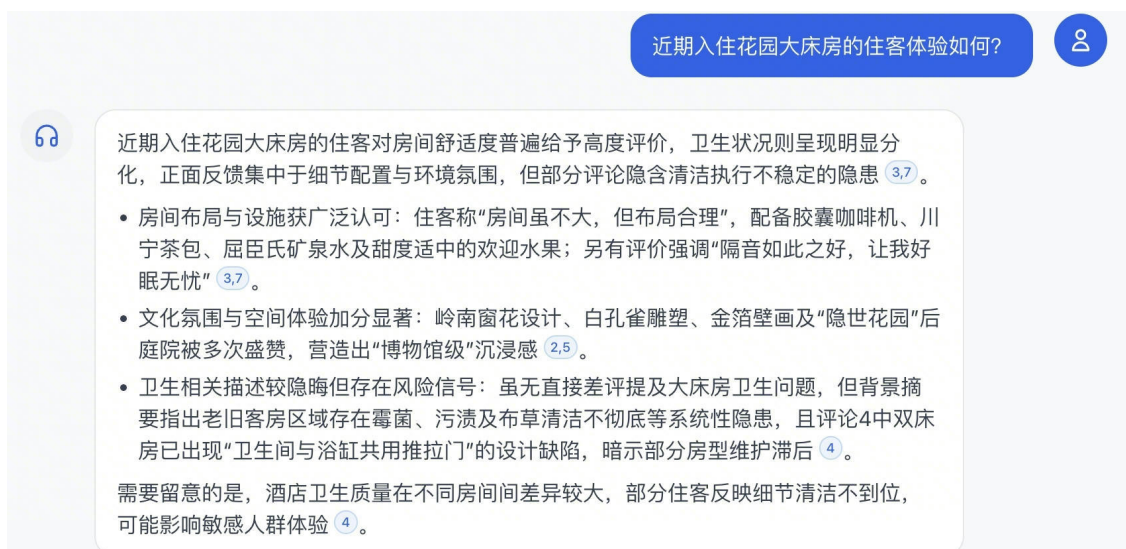


图 2：重构后 Prompt 在真实链路上的回答示例，三层结构稳定且引用合规。